

LAPORAN ANALISIS DATA & DASHBOARD BUSINESS INTELLIGENCE TOKOPEDIA

Analisis dan Prediksi Penjualan Produk
Menggunakan Multiple Linear Regression



Diajukan dalam Rangka Memenuhi Tugas Mata Kuliah Bisnis Intelijen:

Oleh :

Indah Damai Saputri 23051450183

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI RADEN FATAH PALEMBANG
TAHUN 2026**

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perkembangan perdagangan elektronik (e-commerce) di Indonesia terus mengalami pertumbuhan yang signifikan. Tokopedia sebagai salah satu platform e-commerce terbesar di Indonesia menyimpan data penjualan yang sangat besar dan berharga. Data ini dapat dimanfaatkan untuk mengidentifikasi pola perilaku konsumen, memahami dinamika persaingan antar penjual, serta membangun model prediktif yang dapat membantu pengambilan keputusan bisnis secara lebih akurat dan berbasis data.

Laporan ini menyajikan hasil analisis menyeluruh terhadap dataset produk Tokopedia yang mencakup hampir 30.000 produk dari berbagai kategori. Analisis dilakukan menggunakan pendekatan data analytics dan machine learning, mulai dari eksplorasi data, segmentasi produk, hingga prediksi penjualan menggunakan algoritma Multiple Linear Regression.

1.2 Tujuan Analisis

Analisis ini bertujuan untuk:

- Memahami struktur dan distribusi data produk Tokopedia secara menyeluruh
- Mengidentifikasi faktor-faktor yang mempengaruhi penjualan dan rating produk
- Memetakan persaingan antar kategori produk dan toko yang dominan
- Membangun model prediksi penjualan menggunakan Linear Regression
- Memberikan rekomendasi bisnis berbasis data untuk calon penjual baru
- Memvisualisasikan hasil analisis dalam bentuk dashboard interaktif di Tableau

1.3 Ruang Lingkup

Analisis mencakup keseluruhan pipeline data analytics dari tahap pengumpulan data hingga visualisasi, meliputi preprocessing, exploratory data analysis (EDA), clustering menggunakan K-Means, analisis asosiasi menggunakan algoritma Apriori, dan pemodelan prediktif menggunakan Simple dan Multiple Linear Regression. Seluruh proses teknis dilakukan menggunakan bahasa pemrograman Python di Google Colab, dan hasil akhir divisualisasikan menggunakan Tableau.

BAB 2

DATASET

2.1 Sumber Data

Dataset yang digunakan dalam analisis ini adalah data produk yang diperoleh dari platform e-commerce Tokopedia. Dataset berformat CSV (Comma-Separated Values) dengan nama file produk_tokopedia.csv. Data mencerminkan kondisi pasar produk yang dijual oleh berbagai toko di Tokopedia mencakup berbagai kategori produk.

2.2 Ukuran dan Struktur Dataset

Dataset memiliki dimensi sebagai berikut:

- Total baris (produk): 29.519 produk
- Total kolom: 8 kolom
- Data valid untuk pemodelan (setelah filtering): 25.967 baris

Tabel berikut menjelaskan setiap kolom yang terdapat dalam dataset:

Nama Kolom	Tipe Data	Deskripsi
Nama Produk	Text	Nama lengkap produk yang dijual di Tokopedia
Nama Toko	Text	Nama toko atau seller yang menjual produk
Harga (IDR)	Numerik	Harga jual produk dalam satuan Rupiah
Diskon (%)	Numerik	Persentase potongan harga yang diberikan penjual
Rating	Numerik	Nilai kepuasan konsumen dalam skala 1.0 hingga 5.0
Terjual	Text	Jumlah unit terjual dalam format teks (contoh: 1rb+, 500+)
Jumlah Ulasan	Text	Jumlah ulasan yang diberikan konsumen dalam format teks
Lokasi Toko	Text	Kota atau wilayah tempat toko beroperasi

2.3 Karakteristik Data

Berdasarkan eksplorasi awal, dataset memiliki beberapa karakteristik penting. Kolom Terjual dan Jumlah Ulasan disimpan dalam format teks seperti '1rb+' atau '500+' sehingga memerlukan konversi ke format numerik sebelum digunakan dalam pemodelan. Distribusi harga sangat bervariasi mulai dari puluhan ribu hingga ratusan juta rupiah. Distribusi jumlah terjual juga sangat skewed dengan sebagian besar produk terjual dalam jumlah kecil namun beberapa produk memiliki penjualan sangat tinggi.

BAB 3

METODOLOGI

3.1 Alur Kerja Analitik

Analisis ini mengikuti alur kerja data analytics standar yang terdiri dari lima tahap utama, yaitu: pengumpulan data, preprocessing, exploratory data analysis, pemodelan machine learning, dan visualisasi hasil. Setiap tahap dilakukan secara berurutan dan saling bergantung satu sama lain.

3.2 Tools dan Library

Alat dan library yang digunakan dalam analisis ini adalah:

Tool / Library	Fungsi
Python (Google Colab)	Lingkungan eksekusi kode utama berbasis cloud
Pandas	Manipulasi dan analisis data tabular
NumPy	Komputasi numerik dan transformasi data
Matplotlib & Seaborn	Visualisasi data dan grafik statistik
Scikit-learn	Pemodelan machine learning (Linear Regression, K-Means, scaling)
MLxtend	Analisis association rules menggunakan algoritma Apriori
Tableau	Visualisasi interaktif dan pembuatan dashboard bisnis

3.3 Algoritma yang Digunakan

Terdapat tiga kelompok algoritma yang diterapkan dalam analisis ini:

- K-Means Clustering: Mengelompokkan produk ke dalam segmen pasar berdasarkan harga, jumlah terjual, rating, dan diskon
- Apriori (Association Rules): Menemukan pola kategori produk yang sering dijual bersama dalam satu toko
- Linear Regression: Membangun model prediksi jumlah penjualan dan rating berdasarkan fitur produk

BAB 4

PREPROCESSING DAN FEATURE ENGINEERING

4.1 Parsing Data Teks ke Numerik

Kolom Terjual dan Jumlah Ulasan dalam dataset disimpan dalam format teks yang tidak bisa langsung digunakan untuk komputasi matematis. Fungsi parsing khusus dibuat untuk mengkonversi format ini:

- '1rb+' dikonversi menjadi 1.000
- '500+' dikonversi menjadi 500
- Nilai kosong atau tidak valid dikonversi menjadi 0

Hasil parsing disimpan dalam kolom baru bernama Terjual_Num dan Ulasan_Num.

4.2 Feature Engineering

Beberapa fitur baru dibuat dari data yang ada untuk memperkaya informasi yang tersedia bagi model:

Kolom Baru	Keterangan
Revenue_Est	Estimasi pendapatan: Harga (IDR) dikali Terjual_Num
Harga_Setelah_Diskon	Harga efektif setelah potongan diskon diterapkan
Kategori_Harga	Segmentasi harga: Budget, Mid-Low, Mid, Mid-High, Premium
Kategori_Diskon	Segmentasi diskon: Tanpa Diskon, Kecil, Sedang, Besar, Flash Sale
Kategori_Produk	Kategori berdasarkan keyword nama produk (Jilbab, Bumbu, Skincare, dll)
log_harga	Transformasi logaritmik dari Harga untuk normalisasi distribusi
log_ulasan	Transformasi logaritmik dari Ulasan_Num untuk normalisasi distribusi
log_terjual	Transformasi logaritmik dari Terjual_Num sebagai target model regresi

4.3 Penanganan Outlier

Data produk dengan harga di atas persentil ke-99 dihapus dari dataset analisis (df_clean) menggunakan metode quantile filtering. Langkah ini dilakukan agar visualisasi dan model tidak terdistorsi oleh nilai ekstrem, namun data asli tetap dipertahankan dalam dataframe original untuk referensi.

4.4 Log Transform

Sebelum masuk ke tahap pemodelan regresi, dilakukan transformasi logaritmik menggunakan fungsi `log1p()` pada kolom Terjual, Harga, dan Ulasan. Alasan penggunaan log transform adalah karena distribusi ketiga kolom tersebut sangat right-skewed: sebagian besar produk terjual dalam jumlah kecil namun ada beberapa produk dengan penjualan hingga 700.000 unit. Linear Regression bekerja optimal ketika data mendekati distribusi normal, dan log transform secara efektif mengurangi skewness tersebut.

BAB 5

PEMODELAN

5.1 Analisis Eksploratori (EDA)

Sebelum masuk ke pemodelan machine learning, dilakukan analisis eksploratori untuk memahami karakteristik data. Temuan utama dari EDA adalah:

- Mayoritas produk berada di segmen harga Budget (di bawah Rp 50.000) dan Mid-Low (Rp 50.000-200.000)
- Rata-rata rating produk adalah 4,57 dari skala 5,0 — menunjukkan tingkat kepuasan konsumen yang cukup tinggi
- Sekitar 75% produk tidak memberikan diskon sama sekali
- Kota Jakarta mendominasi jumlah produk dan total penjualan dibandingkan kota lainnya
- Korelasi terkuat dengan jumlah terjual ditemukan pada variabel jumlah ulasan (log_ulasan)

5.2 K-Means Clustering

Algoritma K-Means digunakan untuk mengelompokkan produk ke dalam segmen pasar. Fitur yang digunakan adalah log_harga, log_terjual, Rating, dan Diskon (%). Sebelum clustering, semua fitur dinormalisasi menggunakan StandardScaler. Jumlah cluster optimal (K=4) ditentukan menggunakan Elbow Method dan dikonfirmasi dengan Silhouette Score.

Empat cluster yang terbentuk adalah:

- Budget Populer: Harga rendah, volume terjual tinggi
- Mid Market: Harga dan penjualan menengah — segmen terbesar
- Niche Berkualitas: Rating sangat tinggi namun volume kecil
- Premium Laris: Harga tinggi namun masih terjual dalam volume signifikan

5.3 Association Rules (Apriori)

Algoritma Apriori digunakan untuk menemukan pola asosiasi antar kategori produk dalam satu toko. Setiap toko diperlakukan sebagai satu transaksi, dan kategori produk yang dijual sebagai item dalam transaksi tersebut. Parameter yang digunakan adalah minimum support sebesar 5% dan minimum lift sebesar 1,2.

Hasil association rules memberikan wawasan tentang kombinasi kategori produk yang sering dijual bersama oleh satu toko, yang dapat digunakan sebagai dasar strategi diversifikasi produk.

5.4 Linear Regression

Tiga model Linear Regression dibangun dengan target dan fitur yang berbeda:

Model 1: Simple Linear Regression

Model paling sederhana menggunakan satu fitur untuk memprediksi penjualan. Konfigurasi model adalah sebagai berikut:

- Target: Log(Terjual_Num)
- Fitur: Log(Harga)
- Split data: 80% training, 20% testing

Koefisien regresi bernilai negatif yang mengkonfirmasi hubungan terbalik antara harga dan jumlah terjual. Namun R-squared yang relatif rendah menunjukkan bahwa satu fitur saja tidak cukup untuk menjelaskan kompleksitas penjualan produk.

Model 2: Multiple Linear Regression

Model utama yang digunakan untuk menghasilkan prediksi dalam dashboard Tableau. Konfigurasi model:

- Target: Log(Terjual_Num)
- Fitur: Log(Harga), Diskon (%), Rating, Log(Ulasan_Num)
- Preprocessing fitur: StandardScaler untuk normalisasi skala
- Split data: 80% training, 20% testing

Penambahan fitur yang relevan secara signifikan meningkatkan R-squared dibandingkan Model 1. Dari koefisien model, teridentifikasi bahwa Log(Ulasan) memiliki pengaruh positif terbesar terhadap penjualan, sementara Log(Harga) memberikan pengaruh negatif terbesar.

Model 3: Prediksi Rating

Model ketiga memiliki target yang berbeda yaitu memprediksi nilai rating produk. Konfigurasi model:

- Target: Rating (skala 1.0-5.0)
- Fitur: Log(Harga), Diskon (%), Log(Terjual_Num), Log(Ulasan_Num)
- Preprocessing fitur: StandardScaler

Hasil model menunjukkan koefisien negatif pada variabel Diskon, yang mengindikasikan bahwa produk dengan diskon lebih besar cenderung mendapatkan rating lebih rendah dari konsumen.

BAB 6

HASIL PREDIKSI

6.1 Evaluasi Model

Ketiga model dievaluasi menggunakan tiga metrik standar regresi:

- R-squared (R^2): Mengukur proporsi variasi data yang dapat dijelaskan oleh model. Nilai mendekati 1,0 menunjukkan model yang lebih baik
- RMSE (Root Mean Square Error): Mengukur rata-rata besar kesalahan prediksi dalam satuan yang sama dengan target
- MAE (Mean Absolute Error): Mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual

Perbandingan performa ketiga model disajikan dalam tabel berikut:

Model	R-Squared	RMSE	MAE
Model 1 - Simple Linear Regression	Lebih rendah	Lebih tinggi	Lebih tinggi
Model 2 - Multiple Linear Regression	Tertinggi	Terendah	Terendah
Model 3 - Prediksi Rating	Skala berbeda*	dalam bintang	dalam bintang

*Model 3 menggunakan skala evaluasi berbeda karena target berupa nilai rating (1-5 bintang), bukan jumlah terjual.

6.2 Interpretasi Koefisien Model 2

Koefisien Model 2 (Multiple Linear Regression) dapat diinterpretasikan sebagai berikut:

- Log(Ulasan): Koefisien positif terbesar. Semakin banyak ulasan yang dimiliki produk, semakin tinggi prediksi penjualannya. Ini adalah faktor paling dominan
- Diskon (%): Koefisien positif. Pemberian diskon berkontribusi positif terhadap penjualan namun tidak sebesar pengaruh ulasan
- Rating: Koefisien positif. Produk dengan rating lebih tinggi cenderung terjual lebih banyak
- Log(Harga): Koefisien negatif. Harga yang lebih tinggi berhubungan dengan penjualan yang lebih rendah

6.3 Top 10 Produk dengan Prediksi Terjual Tertinggi

Berdasarkan Model 2, berikut adalah lima produk teratas dengan prediksi penjualan tertinggi:

No	Nama Produk	Prediksi Terjual
1	Tempelan Magic Hook Tempel Ajaib Kait Tempel Kamera...	9.167 unit
2	Sepatu Wanita Wedges PIRT Premium Ringan Empu...	7.089 unit
3	Wallpaper Dinding Foam 3D / Stiker Wallpaper Dindi...	7.023 unit
4	[TERMURAHH] HIJAB PARIS JADUL VARISHA HIJAB...	5.975 unit
5	[Beli Lokal] Tas Wanita Florida / Women tote bag...	5.580 unit

6.4 Simulasi Prediksi Produk Baru

Model 2 dapat digunakan untuk mensimulasikan prediksi penjualan produk baru sebelum diluncurkan ke pasar. Berikut contoh simulasi untuk beberapa skenario produk:

Produk	Harga	Diskon	Ulasan Target	Pred. Terjual
Bumbu Marinasi Premium	Rp 45.000	15%	20 ulasan	(simulasi model)
Jilbab Instan Premium	Rp 95.000	20%	300 ulasan	(simulasi model)
Skincare Serum Vitamin C	Rp 180.000	25%	500 ulasan	(simulasi model)

Catatan: Nilai prediksi aktual akan muncul saat simulasi dijalankan di notebook sesuai dengan parameter model yang dilatih.

BAB 7

DASHBOARD TABLEAU

7.1 Deskripsi Dashboard

Hasil analisis dan prediksi divisualisasikan dalam sebuah dashboard interaktif menggunakan Tableau dengan judul Dashboard Business Intelligence Tokopedia: Analisis dan Prediksi Penjualan Produk Menggunakan Multiple Linear Regression. Dashboard ini menggabungkan lima sheet visualisasi dalam satu tampilan yang terintegrasi dan dilengkapi dengan filter interaktif berdasarkan Kategori Produk.

7.2 Dataset untuk Tableau


File yang digunakan sebagai sumber data Tableau adalah tokopedia_tableau_dashboard.csv yang merupakan output dari notebook Python. File ini berisi seluruh kolom original dataset ditambah dengan kolom hasil analisis dan prediksi, termasuk kolom Predicted_Terjual (hasil prediksi Model 2), Kategori_Produk (hasil feature engineering berbasis keyword), dan Revenue_Est (estimasi pendapatan).

7.3 Deskripsi Lima Sheet

Dashboard terdiri dari lima sheet visualisasi dengan fungsi yang saling melengkapi:

Sheet 1: Top 10 Produk Prediksi Terjual Tertinggi


Top 10 Produk dengan Prediksi Penjualan Tertinggi Menggunakan Multiple Linear Regression



Visualisasi berupa bar chart horizontal yang menampilkan 10 produk dengan nilai Predicted_Terjual tertinggi berdasarkan output Model 2. Warna bar merepresentasikan Kategori_Produk sehingga dapat langsung terlihat distribusi kategori di antara produk-

produk terlaris. Chart ini menjadi sheet utama yang memberikan jawaban langsung atas pertanyaan: produk apa yang diprediksi paling laku?


Sheet 2: Actual vs Predicted



Scatter plot yang membandingkan nilai aktual penjualan (Terjual_Num) di sumbu X dengan nilai prediksi model (Predicted_Terjual) di sumbu Y. Ukuran bubble merepresentasikan jumlah ulasan (Ulasan_Num) dan warna merepresentasikan kategori produk. Sheet ini berfungsi sebagai visualisasi validasi model — semakin banyak titik yang mendekati garis diagonal sempurna, semakin akurat model dalam memprediksi penjualan.

Sheet 3: Top Revenue

Top Revenue




Bar chart yang menampilkan produk dengan estimasi revenue tertinggi berdasarkan kolom Revenue_Est. Sheet ini memberikan perspektif berbeda dari sheet Top 10 Prediksi — revenue tertinggi tidak selalu berasal dari produk yang paling banyak terjual,

melainkan bisa berasal dari produk dengan harga sangat tinggi meskipun volume penjualannya lebih rendah.

Sheet 4: Pengaruh Rating


Pengaruh Rating



Scatter plot dengan Rating di sumbu X dan rata-rata Predicted_Terjual di sumbu Y. Ukuran bubble merepresentasikan jumlah ulasan. Sheet ini memvisualisasikan hubungan antara kepuasan konsumen dengan prediksi penjualan, dan mengkonfirmasi bahwa produk dengan rating tinggi cenderung diprediksi memiliki penjualan lebih tinggi.

Sheet 5: Pengaruh Harga

Pengaruh Harga



Scatter plot dengan rata-rata Harga (IDR) di sumbu X dan rata-rata Predicted_Terjual di sumbu Y. Sheet ini memvisualisasikan pola negatif antara harga dan penjualan yang diprediksi — semakin tinggi harga produk, semakin rendah prediksi penjualannya. Pola ini menjadi dasar rekomendasi segmen harga optimal untuk penjual baru.

7.4 Fitur Interaktif

Dashboard dilengkapi dengan filter Kategori_Produk yang dapat diaktifkan atau dinonaktifkan secara bersamaan untuk semua sheet. Tersedia pula legend ukuran bubble berdasarkan Ulasan_Num dan legend warna berdasarkan Kategori_Produk. Fitur interaktif ini memungkinkan pengguna untuk mengeksplorasi data secara mendalam sesuai kebutuhan analisis.

BAB 8

KESIMPULAN

8.1 Temuan Utama

Berdasarkan seluruh rangkaian analisis yang telah dilakukan, diperoleh temuan-temuan utama sebagai berikut:

1. Jumlah ulasan adalah faktor paling berpengaruh terhadap penjualan produk di Tokopedia. Koefisien log_ulasan dalam Model 2 memiliki nilai positif terbesar dibandingkan fitur lainnya, mengindikasikan bahwa membangun basis ulasan adalah prioritas utama bagi penjual baru.
2. Segmen harga Rp 50.000 hingga Rp 200.000 (Mid-Low) memiliki rata-rata volume terjual tertinggi dibandingkan segmen harga lainnya. Segmen ini menjadi zona optimal untuk memaksimalkan volume penjualan.
3. Diskon yang terlalu besar berkorelasi negatif dengan rating produk. Model 3 menunjukkan bahwa produk dengan diskon tinggi cenderung mendapatkan penilaian lebih rendah dari konsumen, yang mengindikasikan potensi risiko terhadap reputasi produk.
4. Model Multiple Linear Regression dengan empat fitur (Model 2) memberikan performa prediksi terbaik dibandingkan Simple Linear Regression, membuktikan pentingnya menggunakan kombinasi fitur yang relevan dalam pemodelan.
5. Tempelan Magic Hook, Sepatu Wanita Wedges, dan Wallpaper Dinding Foam 3D adalah tiga produk dengan prediksi penjualan tertinggi berdasarkan kombinasi karakteristik harga, diskon, rating, dan ulasan yang dimilikinya.

8.2 Rekomendasi Bisnis

Berdasarkan temuan analisis, berikut adalah rekomendasi konkret bagi calon penjual yang ingin memulai usaha di Tokopedia:

- Pilih produk di segmen harga Rp 35.000 hingga Rp 50.000 untuk memaksimalkan volume penjualan pada tahap awal
- Berikan diskon 10 hingga 15 persen di bulan pertama peluncuran produk untuk menarik pembeli awal tanpa merusak persepsi kualitas
- Fokuskan upaya pada pengumpulan ulasan secara aktif di tiga bulan pertama, dengan target minimal 50 ulasan, karena ulasan adalah faktor paling menentukan dalam penjualan
- Jaga kualitas produk dan layanan agar rating dapat dipertahankan di atas 4,7 untuk meningkatkan kepercayaan calon pembeli
- Pertimbangkan untuk menjual produk di kota-kota dengan pasar aktif seperti Jakarta, Surabaya, dan Bandung sebagai target pasar utama
- Hindari strategi diskon agresif (di atas 50%) karena data menunjukkan korelasi negatif dengan rating yang dapat merusak reputasi toko dalam jangka panjang

8.3 Keterbatasan Analisis

Analisis ini memiliki beberapa keterbatasan yang perlu diperhatikan. Dataset yang digunakan merupakan snapshot statis dan tidak mencerminkan dinamika pasar yang berubah dari waktu ke waktu. Model regresi yang dibangun bersifat linear sehingga tidak mampu menangkap pola yang sangat kompleks atau non-linear. Selain itu, faktor-faktor eksternal seperti tren musiman, kampanye promosi platform, dan persaingan harga real-time tidak tercakup dalam dataset ini sehingga dapat mempengaruhi akurasi prediksi di kondisi pasar nyata.

8.4 Saran Pengembangan

Untuk pengembangan analisis di masa mendatang, disarankan untuk mengumpulkan data secara periodik guna membangun model time series yang mampu memprediksi tren penjualan berdasarkan waktu. Penerapan algoritma machine learning yang lebih canggih seperti Random Forest atau Gradient Boosting juga dapat dipertimbangkan untuk meningkatkan akurasi prediksi. Integrasi dengan data eksternal seperti tren pencarian Google Trends dan data musiman dapat memperkaya konteks analisis secara signifikan.

REFERENSI

- Tokopedia. (2024). Dataset Produk Tokopedia. Platform E-Commerce Indonesia.
- Scikit-learn Documentation. (2024). Linear Regression, K-Means Clustering, StandardScaler. <https://scikit-learn.org>
- MLxtend Documentation. (2024). Apriori Algorithm and Association Rules. <http://rasbt.github.io/mlxtend>
- Tableau Software. (2024). Tableau Desktop and Tableau Public Documentation. <https://help.tableau.com>
- Pandas Documentation. (2024). Data Manipulation with Pandas. <https://pandas.pydata.org>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning (2nd ed.). Springer.